

Отчёт по кейсу
«Двухэтапный мониторинг природных пожаров
по данным VIIRS, Sentinel-2 и Sentinel-1»

КосмоХакатон 2026 · Красноярск · 18–20 сентября

Команда	Две калеки
Дата	19.09.2026
Статус	Работающий MVP, submission валиден
Модули	AF (детекция горения) + BS (картирование гарей)
Public score	0.5969

Содержание

1. Задача и метрика

- 1.1. Два модуля
- 1.2. Метрика
- 1.3. Формат submission

2. Данные

- 2.1. Структура
- 2.2. Объёмы
- 2.3. Атрибуты

3. Разведочный анализ (EDA)

- 3.1. AF — ключевые находки
- 3.2. BS — ключевые находки
- 3.3. Инциденты и их разрешение
- 3.4. Сводка наблюдений

4. Модуль AF

- 4.1. Правило детекции
- 4.2. Grid search порогов
- 4.3. Ограничения
- 4.4. Результат на test

5. Модуль BS

- 5.1. Пайплайн
- 5.2. Компоненты
- 5.3. Результат на train
- 5.4. Ограничения
- 5.5. Результат на test

6. Инфраструктура submission

- 6.1. Ключевые модули
- 6.2. Формат RLE
- 6.3. Алгоритм inference
- 6.4. Валидация
- 6.5. Запуск
- 6.6. Информационно-аналитический сервис

7. Результаты на train

- 7.1. Сводная таблица
- 7.2. Разбивка по компонентам
- 7.3. Ожидание на test

7.4. Динамика улучшений

8. Известные ограничения

8.1. Данные

8.2. AF

8.3. BS

8.4. Submission

8.5. Инженерные инциденты

9. Дальнейшие улучшения

9.1. Приоритет 1 (значимый прирост)

9.2. Приоритет 2

9.3. Приоритет 3

9.4. Отрицательные результаты экспериментов

10. Приложения

10.1. Файловая структура

10.2. Запуск с нуля

10.3. Ключевые константы

10.4. Что НЕ вошло в MVP

10.5. Что нужно для воспроизведения

Итог

1. Задача и метрика

1.1. Два модуля

Решение состоит из двух независимых модулей, объединённых общим файлом ответа и информационно-аналитическим сервисом.

- **AF (Active Fire):** по VIIRS-чипу (I1–I5 + aux, 256×256 @ 375 м) найти пиксели природного горения, отфильтровать техногенные термоаномалии. Выход — бинарная маска (1 — горение, 0 — всё прочее).
- **BS (Burn Severity):** по паре Sentinel-2 pre/post, Sentinel-1 pre/post, aux (512×512 @ 20 м) выделить контур гари и классифицировать степень поражения: 0 — не горело, 1 — слабая, 2 — средняя, 3 — сильная.

1.2. Метрика

$$\text{Score} = 0.35 \times F1_{af} + 0.35 \times IoU_{burn} + 0.30 \times mIoU_{sev}$$

- — F1 по классу 1 на всех AF-чипах.
- — IoU бинарной маски «класс ≥ 1» на всех BS-чипах.
- — среднее IoU по классам 1, 2, 3.

Микро-усреднение: TP, FP, FN суммируются по всем чипам, затем считаются precision / recall / F1 / IoU. Если класс отсутствует и в эталоне, и в предсказании — IoU = 1. Если класс есть в эталоне, но не в предсказании — IoU = 0.

1.3. Формат submission

```
chip_id,class_id,rle
AF_te_000001,1,"20 2 34 3"
BS_te_000001,1,"100 5 200 3"
BS_te_000001,2,""
BS_te_000001,3,""
```

447 строк данных (180 AF + 89 BS × 3 класса) + заголовок. RLE в кавычках. Пустой класс — "". Пиксели нумеруются построчно слева направо, сверху вниз, начиная с 1. Пары start length через пробел, по возрастанию, не пересекаются.

2. Данные

2.1. Структура

```
data/
├── train/
│   ├── af/
│   │   ├── viirs/{chip_id}_VIIRS_I1-I5.tif    # 420 чипов
│   │   ├── masks/{chip_id}_MASK.tif
│   │   ├── aux/{chip_id}_AUX.tif
│   │   └── meta.csv
│   └── bs/
│       ├── sentinel2_pre/{chip_id}_Sentinel-2_pre.tif    # 224
│       ├── sentinel2_post/
│       ├── sentinel1_pre/
│       ├── sentinel1_post/
│       ├── masks/
│       ├── aux/
│       └── meta.csv
├── test/
│   ├── af/viirs/                                # 180
│   ├── bs/sentinel2_pre/                        # 89
│   ├── bs/sentinel2_post/
│   ├── bs/sentinel1_pre/
│   ├── bs/sentinel1_post/
│   ├── bs/aux/
│   ├── meta.csv
│   └── sample_submission.csv
└── zipka/                                     # оригиналы архивов
```

2.2. Объёмы

Набор	AF	BS
Train	420 (296 с fires, 124 без)	224
Test	180 (public + private)	89

Всего в train: 9725 fire-пикселей, медиана 21 на положительный чип.

2.3. Атрибуты

AF-чип (8 каналов, float32, 256×256):

#	Канал	Диапазон
1	I1, 640 нм	0.03–0.15
2	I2, 865 нм	0.01–0.27
3	I3, 1610 нм (SWIR)	0.00–0.43
4	I4, 3.74 мкм (MIR)	279–357 K
5	I5, 11.45 мкм (TIR)	278–310 K
6	solar_zenith	43–44°

7	sensor_zenith	34–41°
8	valid	1.0 (бесполезен)

AF-aux (5 каналов, float32): landcover (ESA WorldCover), DEM, t2m, rh2m, wind_speed.

AF-маска: uint8, {0, 1}, nodata=255.

BS Sentinel-2 (10 каналов, uint16, 0–10000): B2, B3, B4, B5, B6, B7, B8A, B11, B12, SCL.

BS Sentinel-1 (2 канала, int16, дБ × 100): VV, VH.

BS-aux (3 канала, int16): topo-index, класс уклона, landcover (ESA WorldCover).

Примечание: в постановке обещали 4 канала (с экспозицией склона), фактически — 3.

BS-маска: uint8, {0, 1, 2, 3}, nodata=255.

3. Разведочный анализ (EDA)

3.1. AF — ключевые находки

Наблюдение 1: valid-канал бесполезен.

Все значения = 1.0. Заменён на $\sim \text{np.isnan}(I4) \& \sim \text{np.isnan}(I5)$. Решение: valid строится только по I4/I5.

Наблюдение 2: у 30% train-чипов I1–I3 полностью NaN.

Диагностика per-band показала: Band I1–I3 — 65536/65536 NaN у 127 из 420 чипов. Band I4–I5 валидны (NaN только в клиньях по краям).

Гипотеза: ночные пролёты VIIRS — видимые каналы не снимаются, MIR/TIR работают. В meta у этих чипов `valid_frac=1.0`, что не соответствует реальности, но fire-пиксели в них есть.

Решение: каналы I1–I3 не используются в правиле детекции. valid строится только по I4/I5.

Наблюдение 3: NaN-маски I1–I5 не всегда совпадают.

Для AF_tr_000001 — совпадают (клин 3856 пикселей). Для AF_tr_000033 — I1–I3 полностью NaN, I4–I5 валидны. Ранняя версия integrity check по I1 дала ложную тревогу «127 битых чипов».

Наблюдение 4: полные NaN-строки/столбцы.

163 чипа имеют частичные NaN-строки/столбцы — это клинья по краям чипа, норма для VIIRS. Не баг

3.2. BS — ключевые находки

Инспекция BS_tr_000001:

- Sentinel-2 pre/post: 10 каналов uint16, 0–10000, CRS EPSG:32638.
- Sentinel-1 pre/post: 2 канала int16 (VV, VH).
- Маска: {0, 1, 2}, класса 3 нет в этом чипе.
- SAR-сигнал: VV упал с -11.8 до -15.5 дБ ($\Delta = -3.7$), VH с -17.3 до -22.7 дБ ($\Delta = -5.3$). Типично для леса — потеря крон снижает объёмное рассеяние.
- Облака: SCL классы {3, 8, 9, 10} — невалидны (cloud shadow, medium/high prob, cirrus).

Наблюдение 5 (BS): расхождение состава аих с постановкой. В постановке обещали 4 канала (высота, уклон, экспозиция, landcover), фактически — 3:

- Band 1: topo-index ($-12 \dots 18$)
- Band 2: класс уклона ($1 \dots 3$)
- Band 3: landcover ESA WorldCover ($10 \dots 90$)

Решение: для dNBR-порогов используем только band 3 (landcover). Топо-index и класс уклона не применяются в baseline.

Наблюдение 6 (BS): SAR-сигнал реагирует на пожар. На BS_tr_000001: $\Delta VV = -3.7$ дБ, $\Delta VH = -5.3$ дБ (падение после пожара). Для леса — типичная картина: потеря крон снижает объёмное рассеяние. **Решение:** SAR не использован в baseline (не хватило времени), но зафиксирован как направление развития.

Наблюдение 7 (BS): класс 3 — самый стабильный в baseline. $IoU(3) = 0.596$ vs $IoU(1) = 0.246$. Пороги strong (0.66/0.386/0.38/0.677) хорошо отделяют сильную степень от фона. Класс 1 — проблемный. **Решение:** не трогаем пороги strong, работаем с weak.

Наблюдение 8: метаданные не отражают реальное покрытие. У 127 AF-чипов `valid_frac = 1.0` в meta.csv, но фактически валидных пикселей 0 ($I1-I3 = NaN$). Реальная доля валидных пикселей для этих чипов — 100% по $I4/I5$, но 0% по $I1-I3$. **Решение:** в собственных расчётах используем маску из растра, а не значение из meta.

3.3. Инциденты и их разрешение

Инцидент 1: ложная тревога по «битым» AF-чипам.

Первая версия `check_af_integrity.py` читала band 1 ($I1$) и объявила 127 из 420 чипов полностью NaN. Это выглядело как баг загрузки. При кросс-проверке с meta.csv выяснилось: у этих 127 чипов `n_fire_px > 0`, то есть физически терялось 12.25% fire-пикселей.

Разбор: диагностика per-band показала, что у этих чипов $I1-I3$ полностью NaN, но $I4-I5$ валидны. Причина — ночные пролёты VIIRS (видимые каналы не снимаются, MIR/TIR работают). Данные не битые, просто каналы имеют разную доступность.

Разрешение: `valid` строится только по $I4/I5$. Каналы $I1-I3$ в правиле не используются. F1 остаётся 0.89 на всём train.

Вывод: не доверять автоматическим integrity-проверкам по одному каналу; сверять с метаданными и другими каналами.

Инцидент 2: структура test-выборки отличалась от train.

Архив `fire-test-renamed.tar` распаковывался в `data/test/test/` (двойная вложенность). Кроме того, в test были папки `af/images/`, `bs/pre/`, `bs/sar_pre/`, которых нет в train.

Разрешение: содержимое `data/test/test/*` перенесено в `data/test/`. Папки `images/`, `pre/`, `sar_pre/` оказались пустыми дублями (0 файлов) — игнорируются. `find_viirs()` в `inference.py` расширен на четыре варианта пути.

Вывод: не полагаться на предполагаемую структуру — проверять фактическую перед запуском.

Инцидент 3: Python ограничивает размер поля CSV (131072 символа).

Валидатор `validate_submission.py` падал с `_csv.Error: field larger than field limit (131072)` на `train`-чипах с крупными пожарами: RLE-строка для 85 fire-пикселей превышала лимит.

Разрешение: `csv.field_size_limit(sys.maxsize)` в начале валидатора.

Вывод: стандартные лимиты Python не рассчитаны на разреженные растровые данные в текстовом формате.

3.4. Сводка наблюдений

#	Наблюдение	Решение
1	<code>valid</code> -канал бесполезен	Используем маску по I4/I5
2	30% AF-чипов имеют NaN в I1–I3 (ночные пролёты)	Не используем I1–I3 в правиле
3	NaN-маски I1–I5 не всегда совпадают	Строим <code>valid</code> по I4/I5
4	Полные NaN-строки/столбцы — клинья по краям	Исключаются через <code>valid</code>
5	BS aux — 3 канала, а не 4	Используем только <code>landcover</code> (band 3)
6	SAR реагирует на пожар (ΔVV , ΔVH)	Зафиксировано как направление развития
7	Класс 3 — самый стабильный (IoU 0.596)	Пороги <code>strong</code> не трогаем
8	<code>valid_frac</code> в <code>meta</code> не соответствует факту	Используем маску из растра

4. Модуль AF

4.1. Правило детекции

```
valid = ~np.isnan(I4) & ~np.isnan(I5)
i4 = nan_to_num(I4, 0)
i5 = nan_to_num(I5, 0)
fire = valid & (i4 >= 330.0) & ((i4 - i5) >= 25.0)
```

Обоснование:

- I4 (3.74 мкм) — основной канал детекции. Очаг 600–1200 К даёт контраст с фоном ~300 К на порядки выше, чем в TIR.
- I4 – I5 — главный признак горения (разность MIR и TIR).
- Порог I4 = 330 К и d45 = 25 К — результат grid search.

4.2. Grid search порогов

Перебор на 420 train-чипах: I4 ∈ {325...345}, d45 ∈ {10...30}, I3 ∈ {0.3...1.0}.

Лучший результат:

```
I4 >= 330 К
I4 - I5 >= 25 К
I3 <= 1.0 (фильтр отключён)
F1 = 0.8902
TP = 8173, FP = 464, FN = 1552
Precision = 0.946, Recall = 0.840
```

Сравнение с baseline:

Правило	F1
I4≥330, d45≥15 (baseline)	0.865
I4≥330, d45≥25 (grid search)	0.890

Прирост +0.025 — вклад ужесточения d45 (снижение FP с 1027 до 464). I3-фильтр не дал прироста: все значения I3 в train < 0.43, порог 1.0 всегда истинен.

4.3. Ограничения

- FN = 1552: слабые/маленькие пожары не детектируются по абсолютному порогу. Контекстный анализ (скользящее окно) не применялся.
- FP = 464: ложные срабатывания на нагретых поверхностях (карьеры, пашня). Фильтр по landcover не реализован.
- Техногенка: газовые факелы по признакам одного снимка неотличимы от природного горения. Фильтр по повторяемости (зимние детекции) не реализован.
- Пороги подобраны на всей train-выборке без выделенной валидации. Возможен переобучающий эффект.


4.4. Результат на test

- AF-чипов: 180.
- Непустых RLE (класс 1): 105 (58%).

- На train было 70% непустых — test ниже, но в пределах ожиданий (другие регионы/сезоны).

5. Модуль BS

5.1. Пайплайн



5.2. Компоненты

NBR:

$$NBR = (B8A - B12) / (B8A + B12 + \text{eps})$$

B8A (865 нм, NIR), B12 (2190 нм, SWIR). Индекс реагирует на потерю хлорофилла (NIR падает) и появление золы (SWIR растёт).

dNBR:

$$dNBR = NBR_pre - NBR_post$$

Пороги по landcover (ESA WorldCover):

Класс	Landcover	Слабая (1)	Средняя (2)	Сильная (3)
10	Лес / кустарник	0.10	0.27	0.66
30	Степь / травяной	0.062	0.204	0.386
40	Пашня	0.07	0.177	0.38
90	Пойма / болото	0.075	0.331	0.677

Обоснование: в лесу запас биомассы в 10 раз выше, чем в степи, поэтому dNBR для одинакового воздействия сильно различается. Единый порог на чип не работает.

Маска облаков:

```
SCL_INVALID = {3, 8, 9, 10} # cloud shadow, cloud med/high, cirrus  
invalid = isin(scl_pre, SCL_INVALID) | isin(scl_post, SCL_INVALID)  
valid = ~invalid
```

Пиксели под облаками не классифицируются → класс 0.

5.3. Результат на train (224 чипа)

Метрика	Значение
IoU_burn	0.3732
IoU(1) — слабая	0.2456
IoU(2) — средняя	0.4005
IoU(3) — сильная	0.5964
mIoU_sev	0.4142

Детализация:

IoU_burn = 0.3732
TP = 5,822,109 FP = 9,692,885 FN = 86,892

mIoU_sev = 0.4142
IoU(1) = 0.2456 (TP=2,151,883 FP=6,399,622 FN=210,988)
IoU(2) = 0.4005 (TP=2,027,270 FP=2,869,303 FN=165,001)
IoU(3) = 0.5964 (TP=1,277,953 FP=788,963 FN=75,906)

Вклад в Score = $0.35 \times 0.3732 + 0.30 \times 0.4142 = 0.2549$

Per-chip IoU_burn: median = 0.366, mean = 0.400, max = 0.988.

Наблюдение: FP >> TP, особенно в классе 1. Порог weak слишком мягкий — baseline находит «слабую гарь» на пашне, фенологических изменениях, границах облаков. Класс 3 — самый стабильный (IoU 0.596).

5.4. Ограничения

- FP >> TP в классе 1 — пороги weak надо поднять.
- SAR не используется. $\Delta VV/\Delta VH$ могли бы помочь там, где оптика закрыта.
- Фенология между pre/post даёт ложные контуры на пашне.
- SCL не безошибочен в полупустыне: сухая светлая почва иногда классифицируется как облако.
- Пороги dNBR взяты из постановки, не откалиброваны на фактических данных train.

5.5. Результат на test

- BS-чипов: 89.
- Непустых RLE: класс 1 — 89 (100%), класс 2 — 89 (100%), класс 3 — 85 (96%).

Ожидаемо: мягкие пороги дают «слабую гарь» на каждом чипе.

6. Инфраструктура submission

6.1. Ключевые модули

Файл	Роль
src/rle.py	RLE encode/decode + self-test на «20 2 34 3»
src/inference.py	Основной скрипт: читает sample_submission.csv, обрабатывает AF и BS, пишет submission
src/validate_submission.py	Проверка формата, дубликатов, RLE, соответствия шаблону
src/bs_baseline.py	BS: dNBR + пороги + облака
src/grid_search_af.py	Подбор порогов AF
src/test_bs_all.py	Оценка BS на train

6.2. Формат RLE

- Пиксели нумеруются построчно слева направо, сверху вниз, начиная с 1.
- Пары start length через пробел.
- Пары по возрастанию, не пересекаются.
- Пустая маска → "".

Пример из постановки: маска 8×8, пиксели 20–21 и 34–36 → «20 2 34 3».

6.3. Алгоритм inference

1. Читаем sample_submission.csv → список (chip_id, class_id).
2. Для каждого AF-чипа: читаем I4/I5, применяем правило, кодируем в RLE.
3. Для каждого BS-чипа: читаем S2 pre/post + AUX + SCL, считаем dNBR, классифицируем по landcover и порогам, кодируем в RLE для классов 1, 2, 3.
4. Пишем CSV: chip_id,class_id,"rle" (кавычки только вокруг RLE).

6.4. Валидация

- Заголовок chip_id,class_id,rle.
- 447 строк данных.
- class_id ∈ {1, 2, 3}.
- RLE: чётное число токенов, start ≥ 1, length ≥ 1, пары по возрастанию.
- Нет дубликатов (chip_id, class_id).
- Множество (chip_id, class_id) совпадает с sample_submission.csv.

Технический нюанс: лимит поля CSV в Python по умолчанию 131072 символа. Увеличен до sys.maxsize — RLE крупных пожаров превышает лимит.

6.5. Запуск

```
python src/inference.py --data-dir data/test --output data/submission.csv
python src/validate_submission.py data/submission.csv --sample
data/test/sample_submission.csv
```

Фактический результат на test:

AF обработано:	180
BS обработано:	89
Строк всего:	447
✔ Submission валиден	

6.6. Информационно-аналитический сервис

Реализован на Streamlit + Plotly. Источник данных — GeoJSON в service/data/. Режимы: local (файлы) / remote (FastAPI) / auto. Функционал:

- Приём пространственно-временного запроса (bbox или GeoJSON-полигон + период).
- Карта термоточек (AF) и контуров гарей (BS) по 3 классам степени.
- Аналитическая справка: площадь в га, распределение по 3 степеням.
- Выгрузка в GeoJSON и JSON.
- Демонстрация на синтетических данных (реальный GeoJSON-контракт готов к подключению результатов моделей).

REST API на FastAPI: эндпоинты /query, /export/thermopoints.geojson, /export/burns.geojson, /export/summary.json.

7. Результаты на train

7.1. Сводная таблица

Метрика	Значение
F1_af	0.8902
IoU_burn	0.3732
mIoU_sev	0.4142
Score (train)	$0.35 \times 0.8902 + 0.35 \times 0.3732 + 0.30 \times 0.4142 = 0.56645$

7.2. Разбивка по компонентам

AF:

Конфигурация	TP	FP	FN	Precision	Recall	F1
Baseline (d45≥15)	8192	1027	1533	0.889	0.842	0.865
Grid search (d45≥25)	8173	464	1552	0.946	0.840	0.890

BS:

Компонент	Значение
IoU_burn	0.3732
IoU класс 1	0.2456
IoU класс 2	0.4005
IoU класс 3	0.5964
mIoU_sev	0.4142

7.3. Ожидание на test

- F1_af: 0.5–0.7 (другие регионы/сезоны, ниже чем 0.89 на train).
- IoU_burn: 0.30–0.40.
- mIoU_sev: 0.35–0.45.

Прогноз Score: $0.35 \times 0.6 + 0.35 \times 0.39 + 0.30 \times 0.41 \approx 0.46$

7.4. Динамика улучшений

Этап	F1_af	IoU_burn	mIoU_sev	Score (train)
Baseline (правила из постановки)	0.865	0.3732	0.4142	0.5367
+ Grid search AF (d45≥25)	0.8902	0.3732	0.4142	0.5469
+ Тюнинг weak BS (+0.03)	0.8902	0.3935	0.4107	0.5577

Прогноз на test: **0.45–0.50**.

8. Известные ограничения

8.1. Данные

- 127 train AF-чипов имеют полностью NaN I1–I3 (ночные пролёты). valid_frac=1.0 в meta не соответствует реальности.
- Метаданные test обезличены: нет acq_datetime, satellite, region, landcover_top, n_fire_px.
- BS-aux содержит 3 канала, а не 4 как в постановке.
- Облачные маски SCL не всегда точны в полупустыне.

8.2. AF

- FN = 1552 на train — слабые/малые пожары не детектируются.
- FP = 464 — техногенка и нагретый грунт.
- Абсолютные пороги без контекстного анализа (скользящее окно).
- Пороги подобраны на всей train-выборке без валидации.

8.3. BS

- FP >> TP в классе 1 — пороги weak слишком мягкие.
- SAR (Sentinel-1) не используется.
- U-Net или LightGBM не применялись.
- Пороги dNBR не калиброваны на фактических данных train.

8.4. Submission

- RLE не проверялся на декодирование обратно в маски с полным пересчётом метрик.
- Класс 3 в BS на test присутствует в 96% чипов — вероятно, избыточно.

9. Дальнейшие улучшения

9.1. Приоритет 1 (значимый прирост)

AF — LightGBM:

- Признаки: I1–I5, I4–I5, I3–I2, landcover, DEM, t2m, rh2m, wind_speed, зенитные углы.
- class_weight='balanced' (класс 1 = 0.035% пикселей).
- Постобработка: binary_opening, удаление компонент <3 пикселей.
- Ожидаемый F1_af: 0.90 → 0.94 на train.

BS — SAR-признаки:

- ΔVV, ΔVH между pre и post.
- В лесу VH падает на 3–6 дБ, в степи VV меняется на 1–2 дБ.
- Помогает там, где оптика закрыта облаками.
- Ожидаемый IoU_burn: 0.37 → 0.42.

9.2. Приоритет 2

- AF: фильтрация техногенки по landcover (застройка, пашня) и OSM (Overpass API).
- AF: контекстный анализ — скользящее окно, относительные пороги.
- BS: U-Net на 15-канальном входе (S2 pre/post + S1 pre/post + dNBR + landcover).
- Кросс-валидация порогов по fire_event_id или регионам.

9.3. Приоритет 3

- Постобработка AF: морфология, удаление мелких компонент.
- Постобработка BS: сглаживание границ, удаление мелких полигонов.
- RdNBR вместо dNBR для класса 1.

9.4. Отрицательные результаты экспериментов

Эксперимент 1: морфологическая постобработка BS.

Гипотеза: FP >> TP в классе 1 — это шум в виде одиночных пикселей. Морфология (opening + closing + component filter) уберёт шум и повысит IoU.

Результаты на train (224 чипа):

Вариант	IoU_burn	mIoU	IoU(1)	Score
baseline	0.3935	0.4107	0.2352	0.2609
opening(3)	0.3569	0.3975	0.2029	0.2442
closing(3)	0.3878	0.3960	0.2343	0.2545
opening+closing+min_size=25	0.3642	0.3985	0.2048	0.2470

Вариант	IoU_burn	mIoU	IoU(1)	Score
min_size=10 (без морфологии)	0.3880	0.4187	0.2351	0.2614

Вывод:

- Opening агрессивно стирает фрагментированные слабые гари (IoU(1) –0.03).
- Closing «раздувает» контуры, снижая IoU(2) на 0.025.
- Фильтр мелких компонент без морфологии даёт +0.0005 — в пределах шума.
- Постобработка **не интегрирована**.

Урок: на разреженной разметке BS пространственные фильтры вредят сильнее, чем помогают. Проблема класса 1 — не в шуме, а в признаках (dNBR не различает фенологию и гарь).

Гипотеза на будущее: для класса 1 нужен RdNBR, SAR или ML-подход, а не постобработка.

10. Приложения

10.1. Файловая структура

```
Project/
├── src/
│   ├── inference.py          # главная точка входа: генерирует submission
│   ├── rle.py                # RLE encode/decode + self-test
│   ├── validate_submission.py # валидатор формата
│   ├── bs_baseline.py        # BS: dNBR + landcover + облака
│   ├── grid_search_af.py     # подбор порогов AF
│   ├── tune_bs_thresholds.py # подбор порогов BS
│   ├── bs_postprocess.py     # морфология (эксперимент)
│   ├── test_bs_all.py        # оценка BS на train
│   ├── inspect_af.py, inspect_bs.py # ручная инспекция чипов
│   └── diagnose_af_bands.py   # диагностика NaN по каналам
├── service/                  # Streamlit UI + FastAPI
│   ├── app.py
│   ├── api.py
│   ├── data/                 # GeoJSON (генерируется или кладётся)
│   └── README.md
├── data/
│   ├── train/                # обучающая выборка
│   ├── test/                 # тестовая выборка
│   ├── artifacts/            # метрики, диагностика (CSV)
│   └── zipka/                 # оригиналы архивов
├── reports/
│   └── Отчёт_Мониторинг_природных_пожаров_КосмоХакатон_2026_1.docx
├── requirements.txt
└── README.md
```

10.2. Запуск с нуля

```
# 1. Установка
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt

# 2. Инференс
python src/inference.py --data-dir data/test --output data/submission.csv

# 3. Валидация
python src/validate_submission.py data/submission.csv --sample
data/test/sample_submission.csv
```

10.3. Ключевые константы

```
# AF
AF_I4_MIN = 330.0      # K
AF_D45_MIN = 25.0      # K
BAND_I4 = 4            # 1-based
BAND_I5 = 5

# BS
S2_B8A = 6             # 0-based
S2_B12 = 8
S2_SCL = 9
SCL_INVALID = {3, 8, 9, 10}
THRESHOLDS = {
    10: (0.13, 0.27, 0.66),
    30: (0.092, 0.204, 0.386),
    40: (0.10, 0.177, 0.38),
    90: (0.105, 0.331, 0.677),
}
```

10.4. Что НЕ вошло в MVP

- Кросс-валидация порогов по `fire_event_id` — не сделано.
- Landcover-фильтр AF — в процессе реализации.
- RdNBR — не реализовано.
- SAR для BS — не реализовано.
- Контекстный анализ AF (скользящее окно) — не реализовано.
- ML (LightGBM для AF, U-Net для BS) — не реализовано (сам факт надобности спорный, нужно экспериментировать по конкретно данному кейсу, ориентировочно + 0.03 public score, что можно достичь и без этого).

10.5. Что нужно для воспроизведения

- Данные: `fire-train-renamed.tar` (2.3 ГБ), `fire-test-renamed.tar` (900 МБ). Распаковать в `data/train/` и `data/test/`.
- Зависимости: `numpy`, `pandas`, `rasterio`.
- Seed: зафиксирован в скриптах (не критично, baseline детерминирован).
- Запуск: `python src/inference.py --data-dir data/test --output data/submission.csv`.

Итог

Проект в состоянии работающего MVP. Submission валиден, оба модуля работают. Дальнейшие улучшения — оптимизация поверх работающего пайплайна.